Informe de Implementación
Clasificador de nivel de tueste de granos de café

Asignatura: Machine Learning

Sección: D-ELEC-N1-IEI-C11

Docente: Emilio Soto

Alumno: Evan Reyes

Fecha: 18 de junio

Índice

Introducción 3

Problema 4

Objetivo 5

Conjunto de datos (dataset) 6

Arquitectura del modelo 7

Entrenamiento 11

Resultados 13

Resultado de predicciones 14

Métricas 18

Precisión y pérdida 18

Matriz de confusión 19

Conclusiones 21

Referencias bibliográficas 22

Introducción

La informática posee una característica que la distingue de muchas otras disciplinas: su capacidad para generar impacto en prácticamente cualquier sector, como la agricultura, la industria, la medicina, las finanzas o la estadística, entre muchos otros. Un profesional del área informática desarrolla soluciones orientadas a optimizar procesos, automatizar tareas y mejorar la eficiencia operativa, permitiendo que organizaciones de distintos rubros puedan incrementar su productividad mediante el uso de la tecnología.

Como es bien sabido, la inteligencia artificial y el aprendizaje automático (Machine Learning) han experimentado un crecimiento significativo desde finales de 2022. Una de las áreas con mayor desarrollo es el reconocimiento de imágenes mediante redes neuronales convolucionales (CNN), las cuales son capaces de identificar patrones visuales y clasificar objetos con altos niveles de precisión. Si bien estas tecnologías existían mucho antes de la aparición de ChatGPT y otros modelos de inteligencia artificial generativa, su popularización ha despertado un gran interés por aprender sobre ellas y ha permitido que cada vez más personas puedan experimentar y desarrollar soluciones basadas en este tipo de algoritmos.

En la industria del café, la clasificación del grado de tueste constituye un proceso fundamental para garantizar la calidad y consistencia del producto final. El nivel de tueste influye directamente en el sabor, aroma y perfil sensorial del café, por lo que una clasificación correcta resulta esencial tanto para productores como para tostadores. Sin embargo, los sistemas industriales capaces de realizar esta tarea de manera automática suelen tener costos elevados, lo que dificulta su adquisición por parte de pequeños emprendimientos o negocios de escala reducida.

Frente a esta problemática, el presente proyecto propone el desarrollo de un modelo de reconocimiento de imágenes basado en una red neuronal convolucional, capaz de clasificar granos de café según su nivel de tueste a partir de fotografías digitales. Para ello, se utiliza un conjunto de datos previamente etiquetado y un proceso de entrenamiento supervisado que permite al modelo aprender las características visuales distintivas de cada categoría.

El desarrollo de este trabajo no solo busca demostrar la aplicación de las técnicas de visión por computador en un contexto real, sino también evidenciar cómo los modelos de Deep Learning pueden convertirse en alternativas de bajo costo frente a soluciones industriales especializadas. De esta manera, se integran los conocimientos adquiridos con una problemática concreta, obteniendo un sistema funcional capaz de clasificar imágenes de granos de café de manera automática con un nivel de precisión confiable.

Problema

En la industria del café de especialidad, el proceso de tueste es una de las etapas más importantes de la producción, ya que es el responsable de desarrollar las características sensoriales del grano. En términos generales, los tuestes oscuros suelen potenciar notas de chocolate, cacao y frutos secos, mientras que los tuestes claros destacan por sus perfiles frutales, florales y cítricos. Por esta razón, clasificar correctamente el grado de tueste es fundamental para garantizar la calidad y consistencia del producto final.

Actualmente, sí que existen equipos industriales capaces de clasificar automáticamente los granos mediante sistemas de visión artificial y sensores ópticos, solucionando el problema. Pero el problema que no soluciona son los precios absurdos, lo que dificulta su adopción por parte de negocios pequeños o incluso medianos.

Se realizó una investigación y estos son algunos ejemplos de las máquinas en el mercado:

- 4.500 dólares: CCD Camera Coffee Bean Color Sorter Machine Automatic Optical Industrial Mini Color Sorting Machine for Sorting Coffee Bean.
- 6.000 dólares: Coffee Bean Color Sorter Coffee Bean Color Sorting Machine.
- 12.000 dólares: Optical Coffee Bean Grading Machine Ai Coffee Bean Color Sorting Machine.

Luego hay máquinas que solo clasifican el grado del tueste y entregan el grado en la escala Agtron o SCAA, la más barata que se encontró fue esta, por unos 720 dólares. Básicamente son máquinas impagables para un negocio pequeño o incluso mediano.

Ante esta situación complicada para negocios humildes, surge la necesidad de desarrollar una alternativa de bajo costo que permita identificar el grado de tueste de un grano de café utilizando únicamente imágenes digitales y técnicas de Machine Learning. Mediante el entrenamiento de una red neuronal convolucional (CNN), es posible construir un sistema capaz de clasificar automáticamente los granos en distintas categorías de tueste (Verde, Claro, Medio y Oscuro), ofreciendo una solución accesible que podría ejecutarse en cualquier computador con un mínimo de recursos.

Con este proyecto, se buscan resultados confiables evaluando el desempeño de un modelo de clasificación de imágenes entrenado con un conjunto de datos etiquetado y analizando su capacidad para reconocer correctamente el nivel de tueste de los granos de café, por una minúscula fracción de lo que cuestan las máquinas industriales.

Objetivo

Desarrollar un modelo de aprendizaje automático basado en redes neuronales convolucionales (CNN) capaz de clasificar el grado de tueste de granos de café a partir de imágenes digitales, proporcionando una alternativa de bajo costo a los sistemas industriales de clasificación óptica.

Objetivos específicos

1. **Preparar y organizar el conjunto de datos de imágenes**, realizando el preprocesamiento necesario para su utilización en el entrenamiento y validación del modelo de clasificación.
2. **Diseñar, implementar y entrenar una red neuronal convolucional (CNN)** en Python utilizando TensorFlow/Keras para identificar las categorías de tueste: Green, Light, Medium y Dark.
3. **Evaluar el desempeño del modelo desarrollado** mediante métricas de clasificación como precisión (accuracy), sensibilidad (recall), F1-score, matriz de confusión, etc, analizando su capacidad para clasificar correctamente el grado de tueste de los granos de café.

Conjunto de datos (dataset)

El siguiente conjunto de datos disponible en Kaggle, ofrece exactamente 1600 imágenes. Un total de 400 por cada categoría. Es una muestra ideal para la implementación de este algoritmo, y será el que se usará para el entrenamiento. En general, tienen una buena calidad y es el dataset más adecuado que se ha encontrado.

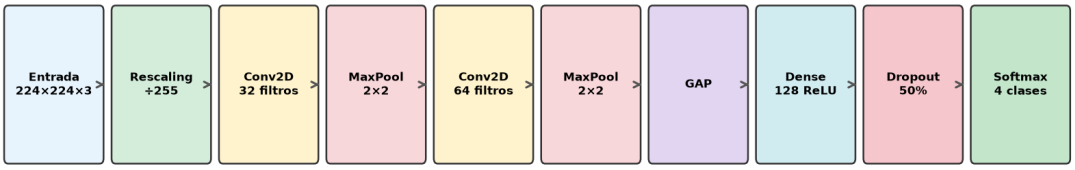
Ejemplo de imagen por cada categoría:

Sin tostar (Verde)	Tueste claro	Tueste medio	Tueste oscuro
			
Dataset: https://www.kaggle.com/datasets/gpiosenka/coffee-bean-dataset-resized-224-x-224			

Arquitectura del modelo

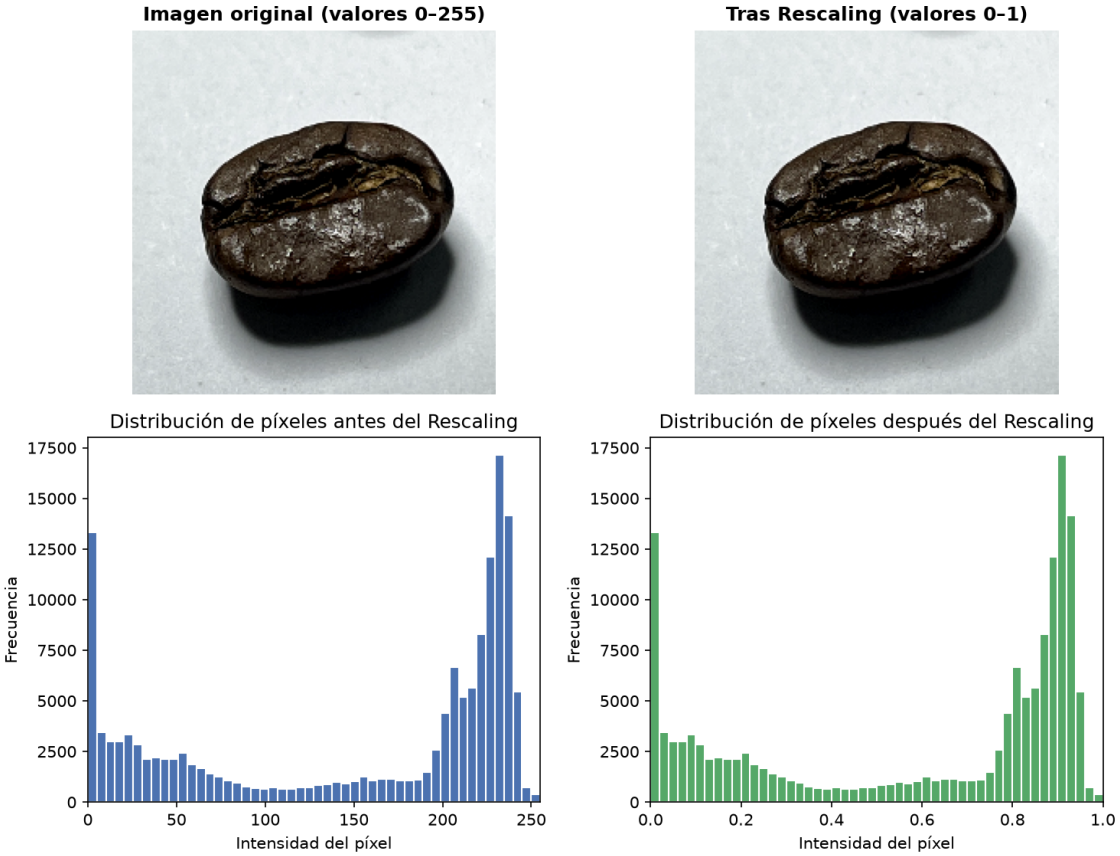
El modelo desarrollado corresponde a una Red Neuronal Convolucional (CNN) implementada mediante la librería de TensorFlow/Keras utilizando una arquitectura secuencial.

Arquitectura secuencial de la CNN para clasificación de tueste de café

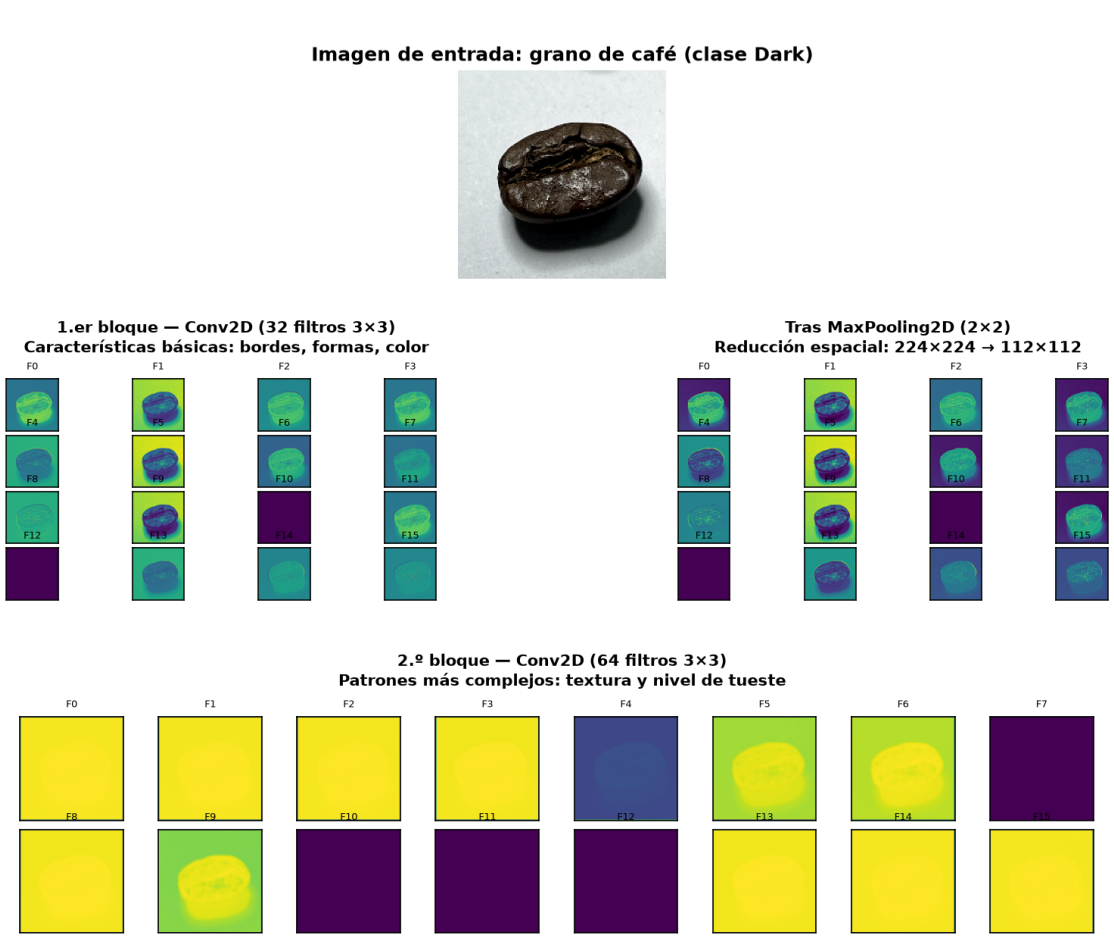


La primera capa del modelo es una capa de normalización (Rescaling), cuya función es escalar automáticamente los valores de los píxeles desde el rango de 0 a 255 hacia un rango entre 0 y 1. Esto permite mejorar la estabilidad y eficiencia del proceso de entrenamiento. La imagen visualmente no cambia.

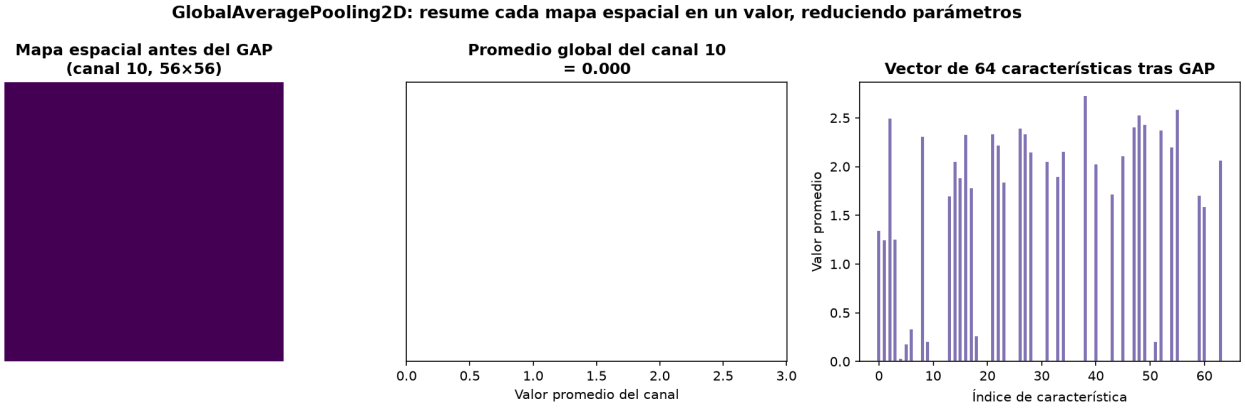
Capa Rescaling: escala automática de píxeles para estabilizar el entrenamiento



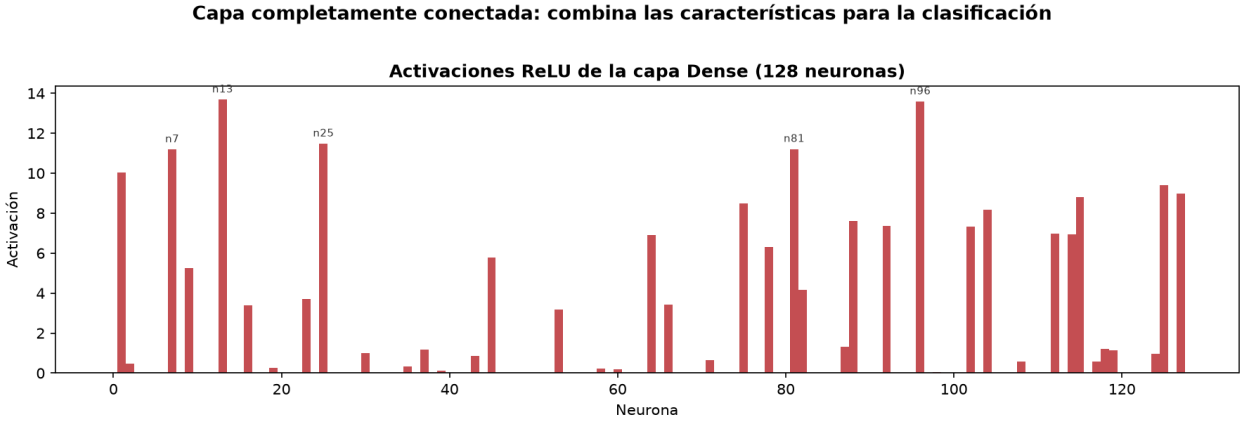
Posteriormente, se incorporan dos bloques convolucionales compuestos por una capa Conv2D seguida de una capa MaxPooling2D. La primera capa convolucional utiliza 32 filtros de tamaño 3×3 para extraer características básicas de las imágenes, como bordes, formas y diferencias de color. El segundo bloque incrementa el número de filtros a 64, permitiendo aprender patrones visuales de mayor complejidad relacionados con la textura y el nivel de tueste de los granos de café.



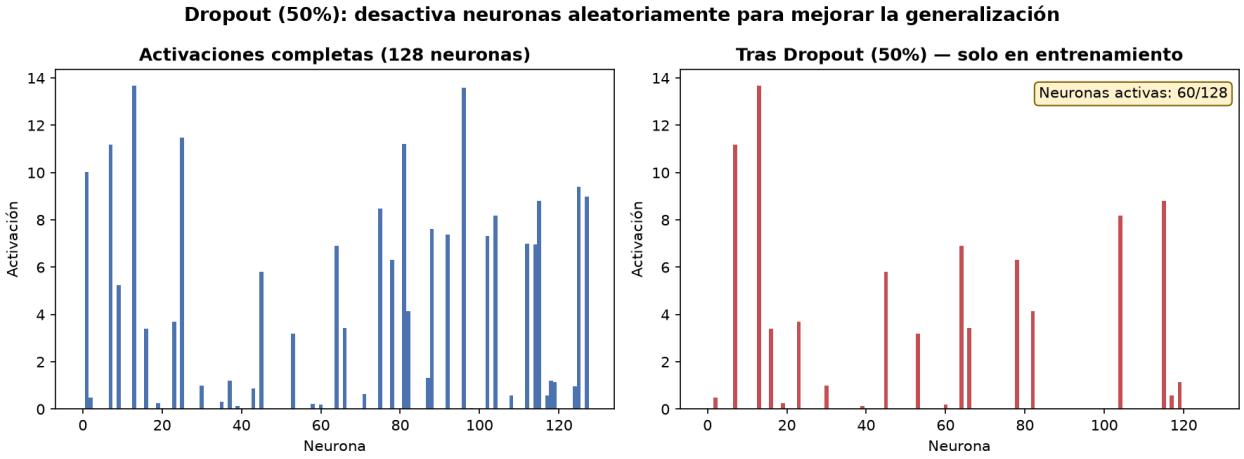
Una vez extraídas las características, la arquitectura emplea una capa GlobalAveragePooling2D, la cual resume la información espacial generada por las capas convolucionales en un vector de características de menor dimensión, reduciendo significativamente el número de parámetros del modelo y disminuyendo el riesgo de sobreajuste.



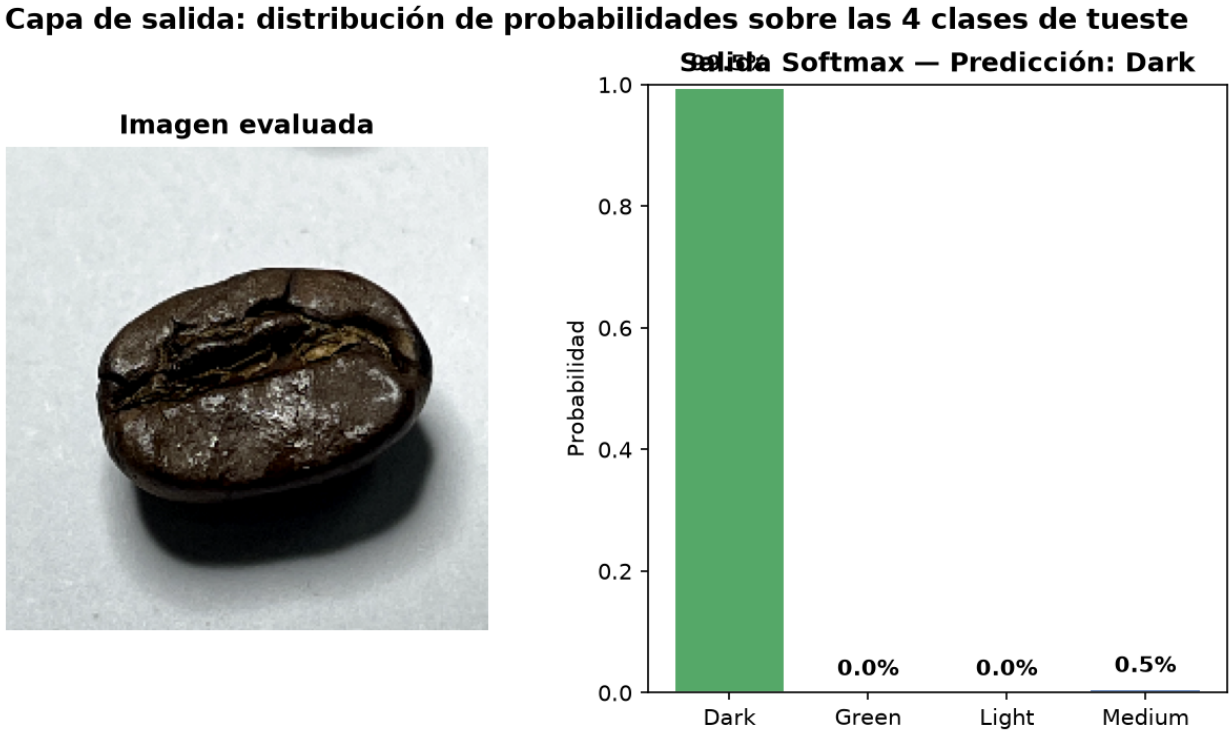
El vector obtenido es procesado por una capa completamente conectada (Dense) de 128 neuronas con función de activación ReLU, encargada de combinar las características aprendidas para realizar la clasificación.



A continuación, se incorpora una capa Dropout con una tasa del 50%, cuyo objetivo es mejorar la capacidad de generalización del modelo evitando que las neuronas dependan excesivamente unas de otras durante el entrenamiento.



Finalmente, la red termina con una capa de salida compuesta por cuatro neuronas y función de activación Softmax, la cual genera una distribución de probabilidades para las cuatro categorías de clasificación consideradas en el proyecto: Green, Light, Medium y Dark. La clase con mayor probabilidad es seleccionada como la predicción final del modelo.



Entrenamiento

Una vez definida la arquitectura de la red neuronal, se procedió al entrenamiento del modelo utilizando las imágenes del conjunto de datos previamente clasificadas según su nivel de tueste. El objetivo de esta etapa es que la red aprenda por sí sola las características que diferencian un grano verde, un tueste claro, un tueste medio y un tueste oscuro.

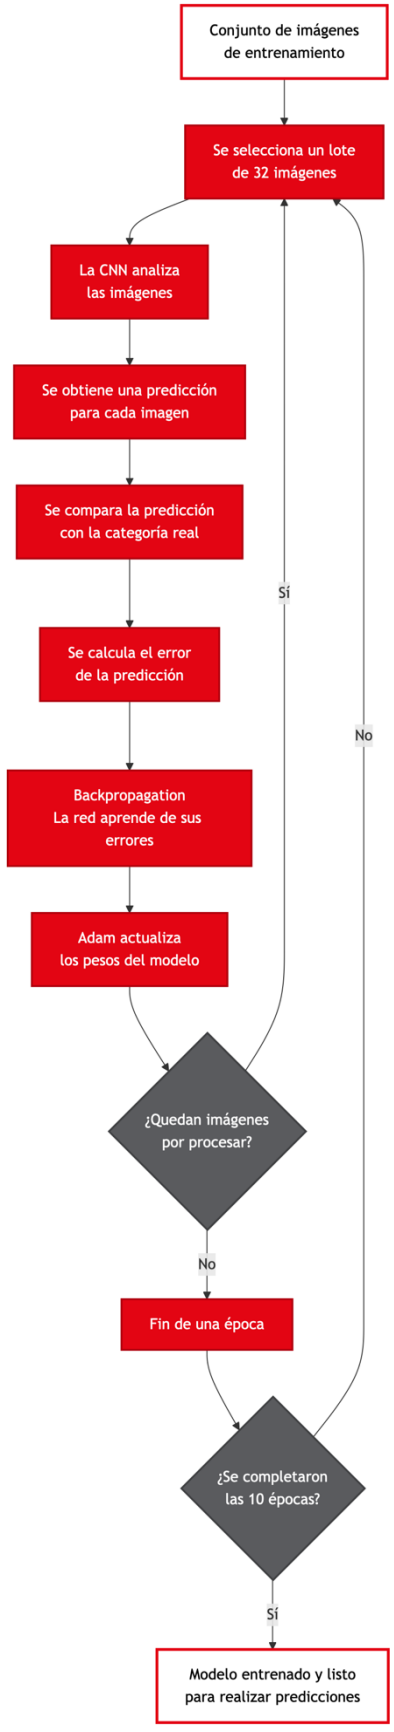
El entrenamiento se realizó procesando las imágenes en grupos de 32 muestras (batch size). En cada grupo, la red analiza las imágenes y genera una predicción para cada una de ellas. Posteriormente, esa predicción se compara con la categoría real de la imagen para calcular qué tan acertada fue la clasificación.

Cuando el modelo comete errores, estos son utilizados para ajustar automáticamente los pesos internos de la red mediante el algoritmo de retropropagación (backpropagation). En términos simples, este proceso permite que la red “aprenda de sus errores”, modificando gradualmente sus parámetros para obtener mejores resultados en las siguientes iteraciones. Este ajuste es realizado por el optimizador Adam, uno de los algoritmos más utilizados en tareas de aprendizaje profundo por su rapidez y estabilidad.

El proceso completo se ejecutó durante 10 épocas. Una época corresponde a recorrer todas las imágenes del conjunto de entrenamiento una vez. Al finalizar cada época, el modelo fue evaluado utilizando el conjunto de prueba para medir su desempeño mediante indicadores como la precisión (accuracy) y la pérdida (loss). Estas métricas permiten observar si el modelo continúa aprendiendo o si ha alcanzado un punto donde ya no obtiene mejoras significativas.

Finalmente, una vez terminado el entrenamiento, el modelo fue almacenado para su utilización en la etapa de predicción. De esta forma, cualquier imagen nueva de un grano de café puede ser ingresada al sistema, el cual analiza sus características visuales y determina automáticamente la categoría de tueste con mayor probabilidad de pertenecer.

A continuación, se adjunta un diagrama de flujo que facilita la comprensión de la explicación.


Conjunto de imágenes de entrenamiento
Se selecciona un lote de 32 imágenes
La CNN analiza las imágenes
Se obtiene una predicción para cada imagen
Se compara la predicción con la categoría real
Se calcula el error de la predicción
Backpropagation La red aprende de sus errores
Adam actualiza los pesos del modelo
¿Quedan imágenes por procesar?
Sí
No
Fin de una época
¿Se completaron las 10 épocas?
No
Sí
Modelo entrenado y listo para realizar predicciones

Resultados

Para comenzar a utilizar el programa, Se debió haber completado el proceso de entrenamiento con el siguiente comando:

```
ZSH
❯ python3 -m src.train

Comienza el entrenamiento del modelo.
Found 1200 files belonging to 4 classes.
Found 400 files belonging to 4 classes.
...
Entrenamiento completado.
Precisión más alta validada: 0.9575
```

`train.py` contiene la lógica del proceso de entrenamiento. esto generó un archivo `coffee_model.keras`.

Ya finalizado el proceso, se puede ejecutar el comando adicional `evaluate` para evaluar el modelo recién entrenado.

```
ZSH
❯ python3 -m src.evaluate

Evaluando modelo.
Found 400 files belonging to 4 classes.
13/13 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 1s 90ms/step
Resultados de la evaluación guardados en results/evaluation_results.txt

=== Resultados de la evaluación ===
Precisión general: 0.9450
Precisión promedio: 0.9452
Recall promedio: 0.9450
F1-Score promedio: 0.9443

=== Métricas por clase ===
Dark:
  Precisión: 0.9596
  Recall: 0.9500
  F1-Score: 0.9548
Green:
  Precisión: 0.9524
  Recall: 1.0000
  F1-Score: 0.9756
Light:
  Precisión: 0.9238
  Recall: 0.9700
  F1-Score: 0.9463
Medium:
  Precisión: 0.9451
  Recall: 0.8600
  F1-Score: 0.9005

Evaluación lista.
```

Se obtiene una precisión general mayor al 90%, lo cual está excelente para probar el modelo.

Resultado de predicciones

Para probar el modelo, se van a seleccionar dos imágenes al azar por cada categoría. Luego, se ejecutará el programa con la consola de Python enviando la imagen como parámetro de ejecución.

Granos Verdes	
dataset/test/Green/green (24).png	dataset/test/Green/green (67).png
	

Resultados obtenidos:

```
ZSH
❯ python3 -m src.predict "dataset/test/Green/green (24).png"
Comienza la predicción.
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 51ms/step
=== Resultados de la predicción ===
Imágen: dataset/test/Green/green (24).png
Clase predicha: Green
Confianza: 99.90%

Detalle de la clasificación:
  1. Green: 99.90%
  2. Medium: 0.05%
  3. Light: 0.03%
  4. Dark: 0.01%
Guardado en results/predictions.txt
Predicción lista.
```

```
ZSH
❯ python3 -m src.predict "dataset/test/Green/green (67).png"
Comienza la predicción.
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 56ms/step
=== Resultados de la predicción ===
Imágen: dataset/test/Green/green (67).png
Clase predicha: Green
Confianza: 99.81%

Detalle de la clasificación:
  1. Green: 99.81%
  2. Medium: 0.10%
  3. Dark: 0.04%
  4. Light: 0.04%
Guardado en results/predictions.txt
Predicción lista.
```

Se obtiene un 99.9 %y un 99.8% de confianza para la categoría Green. Lo cual es correcto.

Para el tueste ligero, se seleccionaron estas dos imágenes

Tueste Ligero (Light)	
dataset/test/Light/light (9).png	dataset/test/Light/light (18).png
	

Y con eso se obtienen los siguientes resultados:

```
ZSH
❯ python3 -m src.predict "dataset/test/Light/light (9).png"
Comienza la predicción.
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 63ms/step
=== Resultados de la predicción ===
Imágen: dataset/test/Light/light (9).png
Clase predicha: Light
Confianza: 91.86%

Detalle de la clasificación:
  1. Light: 91.86%
  2. Medium: 6.15%
  3. Green: 1.99%
  4. Dark: 0.00%
Guardado en results/predictions.txt
Predicción lista.
```

```
ZSH
❯ python3 -m src.predict "dataset/test/Light/light (18).png"
Comienza la predicción.
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 64ms/step
=== Resultados de la predicción ===
Imágen: dataset/test/Light/light (18).png
Clase predicha: Light
Confianza: 98.67%

Detalle de la clasificación:
  1. Light: 98.67%
  2. Medium: 0.95%
  3. Green: 0.38%
  4. Dark: 0.00%
Guardado en results/predictions.txt
Predicción lista.
```

Nuevamente el modelo ha predicho correctamente, con un 91.86% y un 98.67% de confianza.

Se seleccionaron las siguientes imágenes de tueste medio.

Tueste Medio (Medium)	
dataset/test/Medium/medium (16).png	dataset/test/Medium/medium (80).png
	

Resultados obtenidos:

```
                                                ZSH
❯ python3 -m src.predict "dataset/test/Medium/medium (16).png"
Comienza la predicción.
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 64ms/step
=== Resultados de la predicción ===
Imágen: dataset/test/Medium/medium (16).png
Clase predicha: Medium
Confianza: 98.73%

Detalle de la clasificación:
  1. Medium: 98.73%
  2. Dark: 1.23%
  3. Light: 0.04%
  4. Green: 0.00%
Guardado en results/predictions.txt
Predicción lista.
```

```
                                                ZSH
❯ python3 -m src.predict "dataset/test/Medium/medium (80).png"
Comienza la predicción.
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 61ms/step
=== Resultados de la predicción ===
Imágen: dataset/test/Medium/medium (80).png
Clase predicha: Medium
Confianza: 83.69%

Detalle de la clasificación:
  1. Medium: 83.69%
  2. Light: 16.20%
  3. Green: 0.09%
  4. Dark: 0.02%
Guardado en results/predictions.txt
Predicción lista.
```

En esta ocasión, nuevamente ha acertado, con un 98.73% y un 83.69% de confianza.

Para la última categoría, el tueste oscuro. se seleccionaron estas imágenes

Tueste Oscuro (Dark)	
dataset/test/Dark/dark (7).png	dataset/test/Dark/dark (33).png
	

Resultados:

```
                                                ZSH
❯ python3 -m src.predict "dataset/test/Dark/dark (7).png"
Comienza la predicción.
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 54ms/step
=== Resultados de la predicción ===
Imágen: dataset/test/Dark/dark (7).png
Clase predicha: Medium
Confianza: 88.52%

Detalle de la clasificación:
  1. Medium: 88.52%
  2. Dark: 11.25%
  3. Green: 0.12%
  4. Light: 0.11%
Guardado en results/predictions.txt
Predicción lista.
```

```
                                                ZSH
❯ python3 -m src.predict "dataset/test/Dark/dark (33).png"
Comienza la predicción.
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 64ms/step

=== Resultados de la predicción ===
Imágen: dataset/test/Dark/dark (33).png
Clase predicha: Dark
Confianza: 95.77%

Detalle de la clasificación:
  1. Dark: 95.77%
  2. Medium: 4.22%
  3. Green: 0.01%
  4. Light: 0.00%
Guardado en results/predictions.txt
Predicción lista.
```

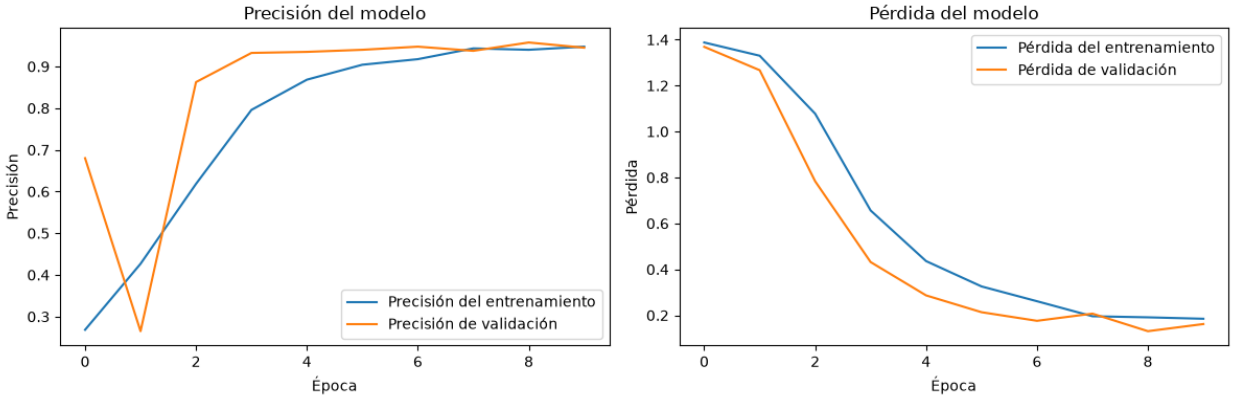
Aquí se “equivocó” por primera vez, clasificando la primera imagen como tueste medio, pero esto es bueno, ya que es precisamente una oportunidad de mejora.

Métricas

Para profundizar en el proceso de entrenamiento, se generaron gráficas relacionadas a la calidad del algoritmo. Aquí se puede entender por qué el modelo se “equivocó” al clasificar el grano de tueste oscuro.

Precisión y pérdida

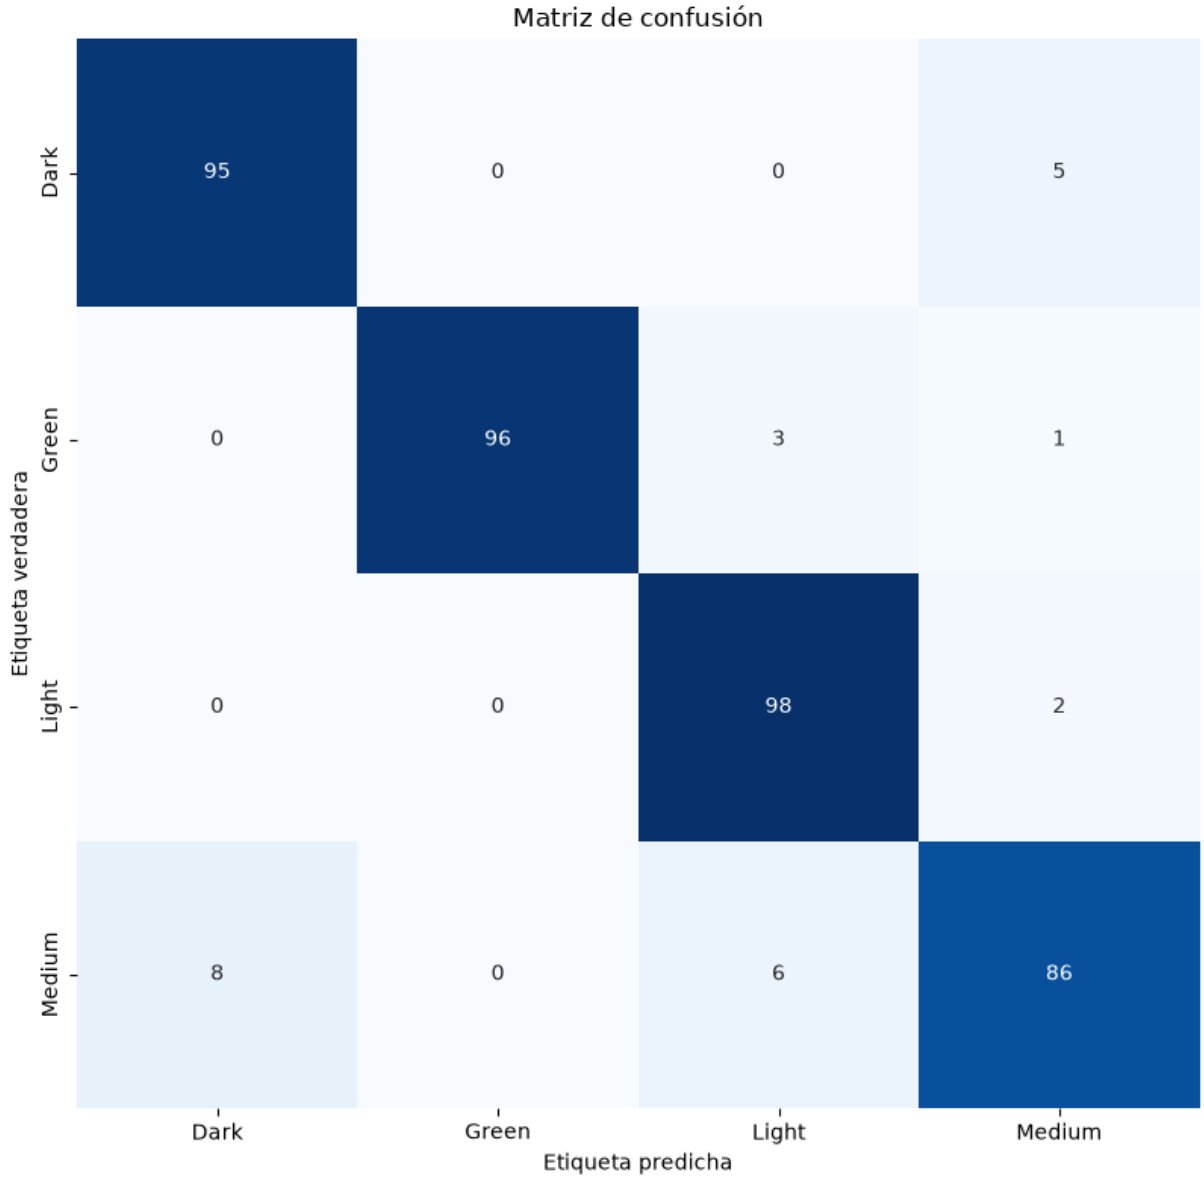
Para el proceso de entrenamiento, se establecieron 10 épocas, es decir, analizar todas las imágenes del conjunto de datos 10 veces. y estos fueron los resultados del entrenamiento:



Como se aprecia en la imagen, la cantidad de épocas definidas parecen ser suficientes en este caso, ya que ambas líneas tanto de entrenamiento y validación están cerca de converger, que es lo que se busca.

Matriz de confusión

Este gráfico nos muestra cómo el modelo ha clasificado una muestra de 100 imágenes por cada grano, la predicción es el eje X y la clasificación correcta se encuentra en el eje Y.



En la matriz de confusión, es esperable que se confunda al categorizar tuestes medios y oscuros, ya que la diferencia es a veces imperceptible (tueste oscuro no significa un color como el carbón).

Aquí podríamos comprender por qué se ha equivocado el modelo con el grano de tueste oscuro que utilizamos en la fase de pruebas, y es porque el modelo no es perfecto en ninguna categoría, donde clasificó cinco granos de tueste oscuro como tueste medio, y es posible que la imagen “dark (7).png” justo sea una de ellas.

También se inspeccionó la muestra de datos manualmente, y se encontraron granos con colores que no corresponderían a su clasificación de tueste, lo que reforzaría la explicación de la confusión. Por ejemplo:

Esto es un café tueste “oscuro”	Y esto un café de tueste “medio”
	
`dataset/train/Dark/dark (26).png`	`dataset/train/Medium/medium (137).png`

Al ver ese ejemplo en específico, cualquiera pensaría que su clasificación es incorrecta, que el tueste medio debe estar clasificado como tueste oscuro y viceversa. Es evidente que la iluminación de la foto tiene la culpa, pero aún con este problema, se obtuvo un buen resultado y obtener un 86/100 (equivalente a 86%) es más que razonable.

Conclusiones

Este proyecto permitió comprender cómo funciona un algoritmo de reconocimiento de imágenes aplicado a un problema real, que soluciona la barrera de precio para acceder a máquinas industriales para clasificar el tueste de granos. Se implementó un algoritmo que llega a imitar el comportamiento en una escala menor.

Durante el desarrollo se aplicaron conceptos fundamentales de Machine Learning y visión por computador, utilizando una CNN capaz de extraer automáticamente características visuales de los granos de café y clasificarlas en cuatro niveles de tueste. Los resultados obtenidos demostraron que este tipo de modelos puede alcanzar un alto nivel de precisión utilizando únicamente imágenes como entrada.

Permitió comprender la importancia de cada etapa del proceso, desde la preparación del conjunto de datos y el entrenamiento del modelo hasta la evaluación mediante métricas como la precisión y la matriz de confusión.

Durante la fase de pruebas, el algoritmo ha fallado con un grano de tueste oscuro, entonces en la próxima instancia, se presentará un modelo mejorado, donde se aplicarán mejoras generales al algoritmo para que la precisión sea mayor y la confusión sea aún menor.

Referencias bibliográficas

Ibm. (2025, 27 noviembre). redes neuronales convolucionales. *IBM Blog*. https://www.ibm.com/es-es/think/topics/convolutional-neural-networks

Team, K. (s. f.). *Keras documentation: Rescaling layer*. https://keras.io/api/layers/preprocessing_layers/image_preprocessing/rescaling/

Coffee Bean Dataset Resized (224 X 224). (s. f.). Kaggle. https://www.kaggle.com/datasets/gpiosenka/coffee-bean-dataset-resized-224-x-224

Team, K. (s. f.-a). *Keras documentation: MaxPooling2D layer*. https://keras.io/api/layers/pooling_layers/max_pooling2d/

¿Qué es Epoch en Machine Learning? – Ciberseguridad. (s. f.). https://ciberseguridad.com/guias/nuevas-tecnologias/machine-learning/epoch/

Constantino, C. (2025, septiembre 24). *Guía de tuestes de café: descubre el mejor tipo para tu método de preparación*. Café Constantino. https://cafeconstantino.cl/blogs/blog-cafe-constantino/guia-tuestes-cafe

Aranda, V. (2023, 10 agosto). Colores del café: La escala Agtron como herramienta esencial del tostado. *Finca de la Vequia*. https://www.fincadelavequia.com/post/colores-del-caf%C3%A9-la-escala-agtron-como-herramienta-esencial-del-tostado