Informe de Mejora de Implementación

Clasificador de nivel de tueste de granos de café

Asignatura: Machine Learning

Sección: D-ELEC-N1-IEI-C11

Docente: Emilio Soto Rojas

Alumno: Evan Reyes Vera

Fecha: 9 de julio de 2026

Tabla de contenido

INTRODUCCIÓN 3
CONTEXTO DE LA IMPLEMENTACIÓN INICIAL 4
LIMITACIONES DETECTADAS EN EL MODELO ANTERIOR 5
OBJETIVO DE LA MEJORA 6
GENERAL 6
ESPECÍFICOS 6
MEJORAS IMPLEMENTADAS 7
NUEVA ARQUITECTURA Y AJUSTES APLICADOS 8
PROCESO DE ENTRENAMIENTO MEJORADO 10
ZSH (ENTRENAMIENTO) 10
ZSH (EVALUACIÓN) 10
RESULTADOS COMPARATIVOS 11
PRECISIÓN Y PÉRDIDA 11
MATRIZ DE CONFUSIÓN 11
MÉTRICAS GENERALES 12
MÉTRICAS POR CADA CLASIFICACIÓN DE GRANO 12
ANÁLISIS DE PREDICCIONES 13
GRANO SIN TOSTAR (VERDE) 13
TUESTE LIGERO 13
TUESTE MEDIO 13
TUESTE OSCURO 13
DISCUSIÓN DE RESULTADOS 14
CONCLUSIONES 17
REFERENCIAS BIBLIOGRÁFICAS 18
ANEXOS 19

Introducción

El presente informe corresponde a la cuarta y última actividad del proyecto de Machine Learning, centrada en la mejora de la implementación inicial de un modelo clasificador de nivel de tueste de granos de café. En etapas anteriores se desarrolló una red neuronal convolucional capaz de clasificar imágenes en cuatro categorías: Green, Light, Medium y Dark. Si bien dicha implementación logró resultados satisfactorios, también permitió identificar ciertas limitaciones, especialmente en la confusión entre clases visualmente similares, como los tuestes Medium y Dark.

A partir de esa primera versión, se realizó un proceso de optimización orientado a mejorar la capacidad de generalización del modelo y aumentar su desempeño frente a nuevas imágenes. Para ello, se incorporaron ajustes en la arquitectura de la red neuronal, mejoras en el preprocesamiento de datos, técnicas de aumento de datos y mecanismos de control del entrenamiento, como EarlyStopping, ReduceLROnPlateau y ModelCheckpoint.

El objetivo de este informe es presentar las mejoras aplicadas al modelo inicial, comparar sus resultados con la versión anterior y analizar si los cambios implementados permitieron reducir los errores detectados. Para esto, se revisan métricas generales, métricas por clase, matrices de confusión y predicciones individuales, prestando especial atención a los casos donde el modelo continúa presentando dificultades.

Se busca demostrar una mejora cuantitativa en el rendimiento del clasificador, también evidenciando el carácter iterativo del desarrollo de soluciones de Machine Learning. En este tipo de proyectos, entrenar un modelo inicial no representa el final del proceso, sino una base desde la cual es posible analizar errores, ajustar la implementación y fortalecer la calidad del sistema paso a paso.

Contexto de la Implementación Inicial

En la implementación inicial se optó por una red neuronal convolucional secuencial, diseñada para clasificar imágenes de granos de café en cuatro categorías de tueste: Dark, Green, Light y Medium. Esta primera versión utilizó una arquitectura simple y directa, compuesta por seis etapas principales:

1. Rescaling: normalización de los valores de píxeles mediante un factor de 1/255, permitiendo que las imágenes pasaran de un rango original de 0 a 255 a un rango entre 0 y 1.
2. Dos bloques convolucionales: cada bloque estaba formado por una capa Conv2D seguida de MaxPooling2D, con el objetivo de extraer características visuales relevantes como bordes, formas, texturas y patrones de color.
3. GlobalAveragePooling2D: reducción de la dimensionalidad de los mapas de características, conservando información relevante antes de pasar a las capas densas.
4. Capa Dense de 128 neuronas: encargada de integrar las características extraídas por las capas convolucionales para apoyar la decisión de clasificación.
5. Dropout de 50%: técnica de regularización aplicada para reducir la dependencia excesiva de ciertas neuronas durante el entrenamiento.
6. Capa Softmax de 4 clases: capa final encargada de asignar una probabilidad a cada clase de tueste y seleccionar la categoría con mayor valor.

Con esta implementación inicial se obtuvieron resultados sólidos para una primera versión del modelo. La precisión general alcanzó un 94.5%, mientras que el F1-score promedio fue de 94.4%, lo que indica un buen equilibrio entre precisión y recall a nivel global.

El mejor desempeño se observó en la clase Green, donde el modelo logró identificar correctamente los ejemplos evaluados con alta consistencia. Esto sugiere que las características visuales del grano verde resultaron más distinguibles para la arquitectura inicial.

Por otro lado, la clase Medium presentó un comportamiento más desafiante en comparación con las demás clases, obteniendo un recall de 86%. Esto indica que, dentro de los casos reales de tueste medio, una parte fue clasificada en otras categorías, es esperable debido a la cercanía visual entre las clases Medium y Dark, lo que se reflejó en algunas confusiones durante la evaluación.

En conjunto, esta primera implementación permitió establecer una base funcional y cuantificable para el problema de clasificación de tueste de café. Sus resultados sirvieron como punto de comparación para analizar posteriormente los efectos de las mejoras incorporadas en la nueva versión del modelo.

Limitaciones detectadas en el modelo anterior

En la primera implementación, el modelo entrenado solía dudar entre un tueste medio y un tueste oscuro. Lo que llevó incluso a clasificar un café de tueste oscuro como tueste medio. Esta en específico:



Pero además del fallo observado en una predicción, el código del modelo inicial muestra ciertas limitaciones.

El modelo anterior tenía una arquitectura CNN relativamente simple, compuesta solo por 2 bloques Conv2D + MaxPooling con filtros de 32 y 64. Para un problema como la clasificación de imágenes de café, donde las diferencias pueden depender de patrones sutiles de color, textura, iluminación y nivel de tostado, esta profundidad puede ser insuficiente para extraer características visuales más complejas.

También, el entrenamiento era fijo a 10 épocas, sin mecanismos de control como EarlyStopping, reducción automática del learning rate o guardado del mejor modelo. Esto limita el proceso de aprendizaje porque el modelo podía quedar subentrenado si necesitaba más épocas, o sobreentrenado si comenzaba a perder capacidad de generalización.

Otra limitación importante es que no existía data augmentation. El modelo entrenaba directamente con las imágenes disponibles, sin generar variaciones como rotaciones, zoom, cambios de contraste o volteos. Esto reduce la capacidad del modelo para generalizar ante imágenes tomadas en condiciones distintas.

Finalmente, el pipeline de datos era más básico: cargaba las imágenes y aplicaba Rescaling(1/255) dentro del modelo, pero no tenía optimizaciones como cache() y prefetch(), ni inspección de distribución de clases. Esto hacía que la implementación fuera menos robusta tanto en rendimiento como en control del entrenamiento.

Objetivo de la mejora

Para enfocar el proceso de mejora, se definieron los siguientes objetivos generales y específicos:

General

Mejorar la implementación inicial del modelo de clasificación de nivel de tueste de granos de café mediante ajustes en el preprocesamiento, arquitectura y entrenamiento, con el fin de aumentar su precisión y reducir errores de clasificación entre categorías visualmente similares.

Específicos

1. Aplicar mejoras técnicas al modelo inicial, incorporando ajustes que permitan aumentar la capacidad de generalización del clasificador.
2. Comparar el desempeño del modelo inicial y el modelo mejorado mediante métricas como accuracy, precision, recall, F1-score y matriz de confusión.
3. Analizar los errores de clasificación restantes, especialmente entre las clases Medium y Dark, para determinar si las mejoras implementadas reducen la confusión observada en la versión anterior.

Mejoras Implementadas

La nueva implementación mejora el modelo en varios aspectos técnicos:

Primero, se amplió la arquitectura CNN personalizada. El modelo anterior tenía dos bloques convolucionales, mientras que este añade un tercer bloque con 128 filtros, permitiendo capturar características visuales más complejas.

Segundo, se incorporó un módulo específico de data augmentation. Durante el entrenamiento se aplican transformaciones como:

```
RandomFlip("horizontal")
RandomRotation(0.05)
RandomZoom(0.1)
RandomContrast(0.1)
```

Esto ayuda a que el modelo sea menos dependiente de las imágenes exactas del dataset y mejore su generalización ante nuevas imágenes.

Tercero, se agregó un pipeline de preprocesamiento separado en preprocessing.py, que aplica redimensionamiento a 224x224, cache() y prefetch(). Esto mejora la organización del código y optimiza el flujo de datos durante entrenamiento y evaluación.

Ahora, el entrenamiento incluye nuevos callbacks:

```
EarlyStopping
ReduceLROnPlateau
ModelCheckpoint
```

Con EarlyStopping, el modelo puede detenerse si la pérdida de validación deja de mejorar. Con ReduceLROnPlateau, el learning rate se reduce automáticamente cuando el entrenamiento se estanca. Con ModelCheckpoint, se guarda el mejor modelo según la precisión de validación.

También se agregó una verificación de distribución de clases antes del entrenamiento, lo que permite detectar posibles desbalances en el dataset.

Nueva arquitectura y ajustes aplicados

La nueva arquitectura mantiene la lógica general de una red neuronal convolucional, pero incorpora ajustes orientados a mejorar la capacidad de extracción de características, la generalización y el control del entrenamiento. A diferencia del modelo inicial, que utilizaba dos bloques convolucionales, el modelo mejorado agrega un tercer bloque Conv2D + MaxPooling2D con 128 filtros. Este cambio permite que la red aprenda representaciones visuales más complejas, especialmente útiles para distinguir diferencias sutiles entre niveles de tueste.

Además, el nuevo modelo incorpora un pipeline de preprocesamiento más estructurado. Aunque se conserva el escalamiento de píxeles mediante Rescaling(1/255), ahora también se utiliza redimensionamiento explícito a 224x224, junto con técnicas de optimización del flujo de datos como cache() y prefetch(). Estas herramientas no modifican directamente la arquitectura del modelo, pero mejoran la eficiencia del entrenamiento y la evaluación.

Otro ajuste importante fue la incorporación de data augmentation durante el entrenamiento. Se aplican transformaciones como volteo horizontal, rotación ligera, zoom y variación de contraste. Esto permite que el modelo observe versiones ligeramente distintas de las imágenes originales, ayudando a reducir la dependencia de condiciones específicas como iluminación, posición o encuadre.

En cuanto a la regularización, se mantiene el uso de Dropout del 50%, pero ahora se complementa con mecanismos adicionales de control del entrenamiento. Entre ellos se incluyen EarlyStopping, ReduceLROnPlateau y ModelCheckpoint. Estos callbacks permiten detener el entrenamiento cuando el modelo deja de mejorar, ajustar automáticamente la tasa de aprendizaje y guardar la mejor versión del modelo según la precisión de validación.

También se amplió la cantidad de épocas disponibles para el entrenamiento. Mientras el modelo inicial se entrenaba durante 10 épocas, la nueva implementación permite entrenar durante más tiempo, llegando a 50 épocas en la ejecución principal y hasta 100 por defecto en la función de entrenamiento. Sin embargo, gracias a EarlyStopping, el entrenamiento no necesariamente utiliza todas las épocas, sino que puede detenerse cuando ya no se observan mejoras relevantes.

Los nuevos ajustes permiten que el modelo mejorado no dependa únicamente de una arquitectura más profunda, sino también de un proceso de entrenamiento más controlado, flexible y preparado para generalizar mejor ante nuevas imágenes.

A modo de resumen, se muestra la siguiente tabla para comparar el nuevo modelo con la implementación anterior:

Elemento	Modelo Inicial	Modelo Mejorado
Preprocesamiento	Rescaling 1/255	Redimensionamiento a 224x224, cache(), prefetch() y Rescaling(1/255) dentro del modelo
Bloques convolucionales	2 Bloques Conv2D + MaxPooling	3 Bloques Conv2D + MaxPooling con filtros 32, 64 y 128
Regularización	Dropout 50%	Dropout 50%, data augmentation, EarlyStopping y reducción automática del learning rate
Entrenamiento	10 épocas	Más épocas + EarlyStopping
Evaluación	Accuracy, F1-Score y matriz	Accuracy, Precision, Recall, F1-Score por clase, matriz de confusión y evaluación pipeline de preprocesamiento

Proceso de Entrenamiento Mejorado

Para comenzar, se entrenó la nueva versión del algoritmo.

ZSH (Entrenamiento)

```
❯ python3 -m src.train
[Solo mostrando el final del output...]
Epoch 50: val_accuracy did not improve from 0.97500
38/38 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 6s 137ms/step - accuracy: 0.9531 - loss: 0.1170 -
val_accuracy: 0.9525 - val_loss: 0.1199 - learning_rate: 1.0000e-05
Restoring model weights from the end of the best epoch: 31.
Saving final model...
Generating training plots...
Training completed successfully!
Best validation accuracy: 0.9750
```

En el momento de la ejecución. El modelo estaba configurado para 100 épocas, pero terminó en la 50 gracias al EarlyStopping. La precisión obtenida fue de 97.5%, en la época 31. A modo comparativo, la precisión obtenida en la implementación anterior fue de 94.5%.

Luego, se prosigue con el comando evaluate, antes de comenzar con las predicciones.

ZSH (Evaluación)

```
❯ python3 -m src.evaluate
Starting model evaluation...
Loading model from models/best_model.keras...
Loading test data...
Found 400 files belonging to 4 classes.
Applying preprocessing pipeline...
Evaluating model...
13/13 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 2s 127ms/step - accuracy: 0.9750 - loss: 0.0971
Generating predictions...
13/13 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 2s 119ms/step
Generating metrics...
Generating plots...
Evaluation results saved to results/evaluation_results.txt

=== Evaluation Summary ===
Overall Accuracy: 0.9750
Average Precision: 0.9750
Average Recall: 0.9750
Average F1-Score: 0.9750

=== Per-Class Metrics ===
Dark:
  Precision: 0.9510
  Recall: 0.9700
  F1-Score: 0.9604
Green:
  Precision: 1.0000
  Recall: 1.0000
  F1-Score: 1.0000
Light:
  Precision: 0.9900
  Recall: 0.9900
  F1-Score: 0.9900
Medium:
  Precision: 0.9592
  Recall: 0.9400
  F1-Score: 0.9495
Evaluation completed successfully!
```

Resultados Comparativos

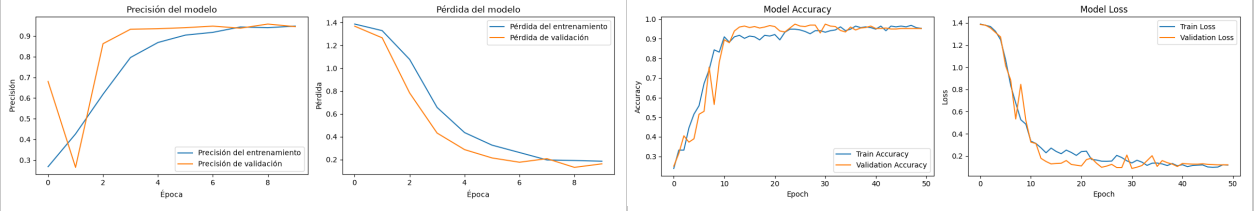
El nuevo modelo obtuvo una precisión del 97.5%. Esta nueva versión, aun implementando rotaciones, contrastes y volteo de imágenes, la precisión aumentó un 3%.

Precisión y Pérdida

A continuación, se aprecia la comparativa entre el gráfico de precisión del modelo y pérdida.

Métricas del entrenamiento

Antiguo	Nuevo

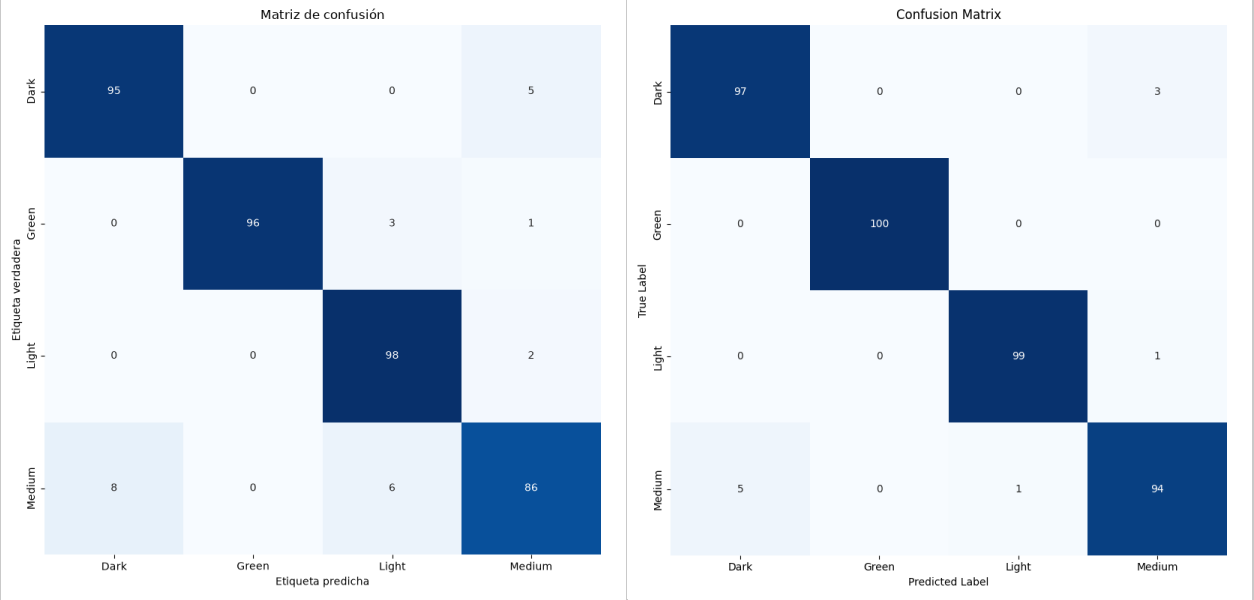


Matriz de confusión

Luego, en la matriz de confusión, también hay mejoras significativas.

Matriz de confusión

Antiguo	Nuevo



Se destaca un aumento de 2 puntos en la predicción del tueste oscuro, una puntuación perfecta para el grano sin tostar, un punto adicional para el tueste ligero, y por último el tueste medio. Ha mejorado en 8 puntos. Un aumento considerable que representa el 3% de mejora general.

Respecto a las otras métricas, estos fueron las mejoras detectadas:

Métricas Generales

Métrica	Modelo Inicial	Nuevo modelo	Diferencia
Precisión General	94.5%	97.5%	+ 3%
Precisión Promedio	94.52%	97.5%	+ 2.98%
Recall Promedio	94.5%	97.5%	+ 3%
F1-Score Promedio	94.43%	97.5%	+ 3.07%

Y para la clasificación del nivel de tueste, estas son las mejoras.

Métricas por cada clasificación de grano

Métrica	Modelo Inicial	Nuevo Modelo	Diferencia
Sin tostar (Verde)			
Precisión	95,24%	100%	+ 4,76%
Recall	100%	100%	= 0%
F1-Score	97,56%	100%	+ 2,44%
Ligero			
Precisión	92,38%	99%	+ 6,62%
Recall	97%	99%	+ 2,00%
F1-Score	94,63%	99%	+ 4,37%
Medio			
Precisión	94,51%	95,92%	+ 1,41%
Recall	86%	94%	+ 8,00%
F1-Score	90,05%	94,95%	+ 4,90%
Oscuro			
Precisión	95,96%	95,10%	- 0,86%
Recall	95%	97%	+ 2,00%
F1-Score	95,48%	96,04%	+ 0,56%

Aunque la precisión del tueste oscuro disminuyó levemente en 0.86%, el recall aumentó en 2%, lo que indica que el modelo mejorado identifica una mayor cantidad de muestras reales de tueste oscuro. Esta mejora en recall sugiere una reducción de falsos negativos, es decir, el modelo deja escapar menos imágenes que pertenecen a esta clase. La pequeña caída en precisión implica que, a cambio, algunas imágenes de otras clases fueron clasificadas erróneamente como tueste oscuro.

Sin embargo, el cambio se considera positivo, ya que el objetivo principal es detectar la mayor cantidad posible de ejemplos reales de tueste oscuro.

Aparte de eso, el modelo muestra mejoras en todas las categorías.

Análisis de Predicciones

El modelo anterior, tuvo dificultades al clasificar un grano de tueste oscuro. Aquí es donde se comprobará si volverá a fallar usando la misma imagen.

Se va a simplificar el muestreo de resultados, omitiendo el resultado explicito que muestra la consola. Esto, para llevarlo a un enfoque de comparativa en vez de enfocado al resultado único. Los resultados explícitos de la consola por cada imagen, quedarán visible en la sección Anexos.

Se utilizarán las mismas imágenes de prueba que se utilizaron para probar la predicción del modelo anterior, pero por cada categoría se van a probar 2 imágenes adicionales, un total de 4 por cada categoría. Las imágenes usadas para el primer modelo serán las primeras 2 filas de cada categoría.

Grano sin tostar (Verde)

Imagen	Clase predicha	Confianza anterior	Confianza Actual
dataset/test/Green/green (24).png	Green	99.90%	99.70%
dataset/test/Green/green (67).png	Green	99.81%	99.33%
dataset/test/Green/green (38).png	Green		97.81%
dataset/test/Green/green (21).png	Green		99.53%

Tueste Ligero

Imagen	Clase predicha	Confianza anterior	Confianza Actual
dataset/test/Light/light (9).png	Light	91.86%	69.39%
dataset/test/Light/light (18).png	Light	98.67%	98.60%
dataset/test/Light/light (50).png	Light		99.82%
dataset/test/Light/light (16).png	Light		99.32%

Tueste Medio

Imagen	Clase predicha	Confianza anterior	Confianza Actual
dataset/test/Medium/medium (16).png	Medium	98.73%	99.39%
dataset/test/Medium/medium (80).png	Medium	83.69%	99.18%
dataset/test/Medium/medium (100).png	Medium		99.35%
dataset/test/Medium/medium (47).png	Medium		91.61%

Tueste Oscuro

Imagen	Clase predicha	Confianza anterior	Confianza Actual
dataset/test/Dark/dark (7).png	Medium	Medium, 88.52%	78.61%
dataset/test/Dark/dark (33).png	Dark	95.77%	99.73%
dataset/test/Dark/dark (68).png	Dark		99.65%
dataset/test/Dark/dark (76).png	Dark		99.24%

Discusión de resultados

Antes de comenzar a interpretar los resultados obtenidos, se sugiere mirar con detención las imágenes que fueron utilizadas en la demostración anterior. Específicamente las de clase Medium y Dark.



Dentro de los primeros hallazgos, es posible pensar que, debido a que la matriz de confusión en la categoría Green obtuvo 100 aciertos, el modelo debería haber predicho las imágenes de esta clase con una confianza del 100%. Sin embargo, esto no necesariamente ocurre. Aunque la precisión, el recall y el F1-score también fueron del 100% para la clase Green, estas métricas evalúan si la clase final predicha fue correcta, no cuánta probabilidad asignó el modelo a dicha predicción.

En otras palabras, una predicción con 98%, 99% o incluso 51% de confianza puede ser considerada correcta si la clase predicha coincide con la clase real. Por eso una métrica global puede ser perfecta mientras que la confianza individual sea menor al 100%. En este caso, el modelo clasificó correctamente las imágenes como Green porque fue la clase con mayor probabilidad, aunque asignó pequeñas probabilidades a otras clases.

Luego, se observa que la confianza del modelo tendió a disminuir en algunos casos frente al modelo anterior. Un ejemplo claro ocurre en la imagen light (9).png, perteneciente al tueste ligero. En esta imagen, la confianza disminuyó de 91.86% a 69.39%, aunque la clase predicha siguió siendo correctamente Light. Esta reducción puede interpretarse como una mayor incertidumbre del modelo frente a una muestra visualmente menos representativa o más ambigua de la clase Light. De hecho, la segunda clasificación más alta para esa imagen fue Medium, con un 30.32%.

Esta disminución no necesariamente representa un empeoramiento. Puede indicar que el nuevo modelo está siendo menos sobreconfiado y que distribuye parte de la probabilidad hacia clases visualmente similares. Esto puede deberse a los ajustes incorporados en la nueva implementación, como el uso de data augmentation, mayor regularización, más épocas, etc. Estas técnicas pueden hacer que el modelo generalice mejor, aunque en algunos casos entregue predicciones con menor confianza.

En los resultados de la clase Medium, se puede apreciar un aumento de confianza, lo cual resulta coherente con los resultados anteriores. En la matriz de confusión del modelo inicial, esta era una de las categorías con mayores problemas de predicción. Por lo tanto, el incremento de confianza en esta clase sugiere que el modelo mejorado logró aprender características más representativas del tueste medio, reduciendo parte de la confusión observada previamente.

En la clase Dark, nuevamente aparece un caso relevante con la imagen dark (7).png. Inicialmente se esperaba que el nuevo modelo pudiera mitigar esta confusión, sobre todo de parte de quien escribe, pero la imagen continuó siendo clasificada erróneamente como Medium. No obstante, la confianza de esta predicción incorrecta disminuyó de 88.52% a 78.61%, lo que indica que el modelo actual está menos seguro de esa decisión. Esto puede interpretarse como una mejora parcial en la calibración del modelo, ya que sigue fallando, pero con menor sobreconfianza.

Además, al revisar las otras clasificaciones para esa imagen, se observa que la confianza asignada a la clase correcta Dark aumentó de 11.25% a 21.37%. Esto sugiere que el nuevo modelo reconoce con mayor fuerza algunos rasgos asociados al tueste oscuro, aunque todavía no son suficientes para superar la probabilidad asignada a Medium. Por lo tanto, aunque la predicción final sigue siendo incorrecta, existe una mejora parcial en la forma en que el modelo interpreta la imagen.

Este caso también permite mencionar la posible ambigüedad visual de la imagen dark (7).png. A simple vista, la imagen podría parecer más cercana a un tueste medio que a uno oscuro (Opinión subjetiva), lo que explicaría por qué ambos modelos la clasifican como Medium. Es por eso que se comenzó esta sección con una tabla de todas las imágenes utilizadas. Esto sugiere que el problema puede no estar únicamente en la arquitectura del modelo, sino también en la calidad, iluminación o características visuales.

Pero que haya fallado nuevamente no representa un deterioro general del modelo para la clase Dark. En la misma comparación, otras imágenes de tueste oscuro fueron clasificadas correctamente con alta confianza. Por ejemplo, dark (33).png aumentó de 95.77% a 99.73%, mientras que dark (68).png y dark (76).png obtuvieron 99.65% y 99.24%, respectivamente. Por tanto, el problema parece estar concentrado en esa muestra específica y no en la capacidad general del modelo para reconocer la clase Dark.

Los resultados muestran que no basta con analizar únicamente métricas globales como accuracy, precision, recall o F1-Score. También es necesario revisar predicciones individuales, especialmente aquellas donde el modelo falla o presenta baja confianza. Estos casos permiten identificar imágenes ambiguas, posibles problemas de etiquetado o semejanzas visuales difíciles entre clases.

Una mejora global del modelo no implica eliminar todos los errores individuales. En problemas de clasificación de imágenes de café, las diferencias entre tuestes pueden ser graduales y visualmente cercanas. Por ello, casos como dark (7).png son útiles para comprender las limitaciones del modelo y proponer mejoras futuras, como revisar manualmente imágenes ambiguas, aumentar la cantidad de ejemplos similares, mejorar el balance del dataset o utilizar Transfer Learning para extraer características visuales más robustas.

A pesar de las mejoras obtenidas, el modelo aún depende de la calidad del dataset y de las condiciones visuales de cada imagen. La confusión en dark (7).png demuestra que existen muestras ambiguas donde incluso una arquitectura mejorada puede tener dificultades. Esto abre la posibilidad de realizar futuras mejoras mediante revisión manual del etiquetado, incorporación de más imágenes reales y uso de Transfer Learning.

Conclusiones

La mejora de la implementación inicial permitió comprobar que el desarrollo de un modelo de Machine Learning es un proceso iterativo, donde los resultados de una primera versión sirven como base para identificar debilidades y aplicar ajustes técnicos más específicos. En este caso, el modelo inicial ya presentaba un buen desempeño general, pero mostraba dificultades en la clasificación de tuestes visualmente cercanos, especialmente entre las clases Medium y Dark.

A partir de las mejoras implementadas, el modelo logró aumentar su exactitud general desde 94.5% hasta 97.5%, lo que representa una mejora de 3 puntos porcentuales. Además, se observaron avances importantes en métricas por clase, destacando especialmente el aumento del recall en la categoría Medium, que pasó de 86% a 94%. Esto demuestra que la nueva arquitectura, junto con el uso de data augmentation, callbacks y un pipeline de preprocesamiento más robusto, contribuyó a mejorar la capacidad de generalización del clasificador.

Sin embargo, los resultados también muestran que una mejora global no implica la eliminación total de los errores individuales. La imagen dark (7).png continuó siendo clasificada como Medium, aunque con una confianza menor que en el modelo anterior. Este caso permite evidenciar que algunos errores pueden estar relacionados no solo con la arquitectura del modelo, sino también con la ambigüedad visual de ciertas imágenes, las condiciones de iluminación o incluso posibles inconsistencias en el etiquetado del dataset.

La versión mejorada del clasificador representa un avance significativo respecto a la implementación inicial, tanto en rendimiento como en robustez del proceso de entrenamiento. El proyecto permitió aplicar conceptos relevantes de visión por computador, redes neuronales convolucionales, regularización, evaluación de métricas y análisis de errores. Sería recomendable revisar manualmente las imágenes ambiguas del dataset, incorporar fotografías tomadas en condiciones reales y evaluar técnicas más avanzadas, con el fin de mejorar aún más la clasificación de niveles de tueste en escenarios prácticos.

Referencias bibliográficas

Ibm. (2025, 27 noviembre). redes neuronales convolucionales. *IBM Blog*. https://www.ibm.com/es-es/think/topics/convolutional-neural-networks

Team, K. (s. f.). *Keras documentation: Rescaling layer*. https://keras.io/api/layers/preprocessing_layers/image_preprocessing/rescaling/

Coffee Bean Dataset Resized (224 X 224). (s. f.). Kaggle. https://www.kaggle.com/datasets/gpiosenka/coffee-bean-dataset-resized-224-x-224

Team, K. (s. f.-a). *Keras documentation: MaxPooling2D layer*. https://keras.io/api/layers/pooling_layers/max_pooling2d/

¿Qué es Epoch en Machine Learning? – Ciberseguridad. (s. f.). https://ciberseguridad.com/guias/nuevas-tecnologias/machine-learning/epoch/

Constantino, C. (2025, septiembre 24). *Guía de tuestes de café: descubre el mejor tipo para tu método de preparación*. Café Constantino. https://cafeconstantino.cl/blogs/blog-cafe-constantino/guia-tuestes-cafe

Aranda, V. (2023, 10 agosto). Colores del café: La escala Agtron como herramienta esencial del tostado. *Finca de la Vequia*. https://www.fincadelavequia.com/post/colores-del-caf%C3%A9-la-escala-agtron-como-herramienta-esencial-del-tostado

Anexos

Resultados de las predicciones

Categoría Green

```
❯ python3 -m src.predict "dataset/test/Green/green (24).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Green/green (24).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 41ms/step

=== Prediction Results ===
Image: dataset/test/Green/green (24).png
Predicted Class: Green
Confidence: 0.9970

Top 4 Predictions:
  1. Green: 0.9970
  2. Medium: 0.0023
  3. Dark: 0.0004
  4. Light: 0.0002
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Green/green (67).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Green/green (67).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 65ms/step

=== Prediction Results ===
Image: dataset/test/Green/green (67).png
Predicted Class: Green
Confidence: 0.9933

Top 4 Predictions:
  1. Green: 0.9933
  2. Medium: 0.0050
  3. Dark: 0.0014
  4. Light: 0.0002
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Green/green (38).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Green/green (38).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 68ms/step

=== Prediction Results ===
Image: dataset/test/Green/green (38).png
Predicted Class: Green
Confidence: 0.9781

Top 4 Predictions:
  1. Green: 0.9781
  2. Medium: 0.0192
  3. Dark: 0.0017
  4. Light: 0.0010
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Green/green (21).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Green/green (21).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 40ms/step

=== Prediction Results ===
Image: dataset/test/Green/green (21).png
Predicted Class: Green
Confidence: 0.9953

Top 4 Predictions:
  1. Green: 0.9953
  2. Medium: 0.0034
  3. Dark: 0.0011
  4. Light: 0.0002
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

Categoría Light

```
❯ python3 -m src.predict "dataset/test/Light/light (9).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Light/light (9).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 67ms/step

=== Prediction Results ===
Image: dataset/test/Light/light (9).png
Predicted Class: Light
Confidence: 0.6939

Top 4 Predictions:
1. Light: 0.6939
2. Medium: 0.3032
3. Green: 0.0029
4. Dark: 0.0000
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Light/light (18).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Light/light (18).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 62ms/step

=== Prediction Results ===
Image: dataset/test/Light/light (18).png
Predicted Class: Light
Confidence: 0.9860

Top 4 Predictions:
1. Light: 0.9860
2. Medium: 0.0133
3. Green: 0.0007
4. Dark: 0.0000
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Light/light (50).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Light/light (50).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 72ms/step

=== Prediction Results ===
Image: dataset/test/Light/light (50).png
Predicted Class: Light
Confidence: 0.9982

Top 4 Predictions:
1. Light: 0.9982
2. Medium: 0.0015
3. Green: 0.0003
4. Dark: 0.0000
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Light/light (16).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Light/light (16).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 64ms/step

=== Prediction Results ===
Image: dataset/test/Light/light (16).png
Predicted Class: Light
Confidence: 0.9932

Top 4 Predictions:
1. Light: 0.9932
2. Medium: 0.0059
3. Green: 0.0009
4. Dark: 0.0000
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

Categoría Medium

```
❯ python3 -m src.predict "dataset/test/Medium/medium (16).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Medium/medium (16).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 70ms/step

=== Prediction Results ===
Image: dataset/test/Medium/medium (16).png
Predicted Class: Medium
Confidence: 0.9939

Top 4 Predictions:
  1. Medium: 0.9939
  2. Dark: 0.0061
  3. Light: 0.0000
  4. Green: 0.0000
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Medium/medium (80).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Medium/medium (80).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 81ms/step

=== Prediction Results ===
Image: dataset/test/Medium/medium (80).png
Predicted Class: Medium
Confidence: 0.9918

Top 4 Predictions:
  1. Medium: 0.9918
  2. Light: 0.0078
  3. Dark: 0.0002
  4. Green: 0.0001
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Medium/medium (100).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Medium/medium (100).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 58ms/step

=== Prediction Results ===
Image: dataset/test/Medium/medium (100).png
Predicted Class: Medium
Confidence: 0.9935

Top 4 Predictions:
  1. Medium: 0.9935
  2. Dark: 0.0032
  3. Light: 0.0026
  4. Green: 0.0007
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Medium/medium (47).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Medium/medium (47).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 41ms/step

=== Prediction Results ===
Image: dataset/test/Medium/medium (47).png
Predicted Class: Medium
Confidence: 0.9161

Top 4 Predictions:
  1. Medium: 0.9161
  2. Dark: 0.0806
  3. Green: 0.0031
  4. Light: 0.0003
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

Categoría Dark

```
❯ python3 -m src.predict "dataset/test/Dark/dark (7).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Dark/dark (7).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 41ms/step

=== Prediction Results ===
Image: dataset/test/Dark/dark (7).png
Predicted Class: Medium
Confidence: 0.7861

Top 4 Predictions:
  1. Medium: 0.7861
  2. Dark: 0.2137
  3. Green: 0.0001
  4. Light: 0.0000
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Dark/dark (33).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Dark/dark (33).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 64ms/step

=== Prediction Results ===
Image: dataset/test/Dark/dark (33).png
Predicted Class: Dark
Confidence: 0.9973

Top 4 Predictions:
  1. Dark: 0.9973
  2. Medium: 0.0027
  3. Green: 0.0000
  4. Light: 0.0000
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Dark/dark (68).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Dark/dark (68).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 60ms/step

=== Prediction Results ===
Image: dataset/test/Dark/dark (68).png
Predicted Class: Dark
Confidence: 0.9965

Top 4 Predictions:
  1. Dark: 0.9965
  2. Medium: 0.0035
  3. Green: 0.0000
  4. Light: 0.0000
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```

```
❯ python3 -m src.predict "dataset/test/Dark/dark (76).png"
Starting image prediction...
Loading model from models/best_model.keras...
Loading image from dataset/test/Dark/dark (76).png...
Making prediction...
1/1 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 0s 68ms/step

=== Prediction Results ===
Image: dataset/test/Dark/dark (76).png
Predicted Class: Dark
Confidence: 0.9924

Top 4 Predictions:
  1. Dark: 0.9924
  2. Medium: 0.0076
  3. Green: 0.0000
  4. Light: 0.0000
Prediction results saved to results/predictions.txt
Prediction completed successfully!
```